Memoria Justificativa y Documentación Técnica

Ejercicio 8 - Diseño e Implementación de Data Warehouse (Star Schema)

1. Estructura lógica y modelo en estrella (Star Schema)

En este proyecto se ha diseñado un almacén de datos (Data Warehouse) basado en un esquema en estrella (Star Schema) para el análisis de transacciones financieras. El modelo consta de una tabla central de hechos (fact_transactions) y cuatro tablas de dimensiones principales:

• dim_user: Contiene la información unificada de los usuarios.
• dim_company: Información de las empresas y comercios.
• dim_credit_card: Detalles de las tarjetas de crédito y su relación con los usuarios.
• dim_date: Calendario analítico derivado de las marcas de tiempo de las transacciones.

2. Integración de usuarios y definición de la columna region

Para la creación de la dimensión dim_user, se han combinado los datos de los ficheros american_users.csv y european_users.csv. Con el fin de mantener la trazabilidad geográfica de los usuarios, se ha añadido la columna region, asignando el valor 'US' a los usuarios americanos y 'EU' a los europeos.

3. Relaciones e integridad referencial (Foreign Keys)

Para garantizar la integridad referencial de la base de datos:

• La clave primaria id de dim_user se define como clave foránea (user_id) en la tabla dim_credit_card (relación 1 a N).
• Las claves primarias de las dimensiones (dim_user, dim_company, dim_credit_card, dim_date) actúan como claves foráneas en la tabla central fact_transactions.

4. Tratamiento del campo de productos (product_ids)

La columna product_ids en la tabla central fact_transactions se ha mantenido en formato de texto (VARCHAR). Esta decisión permite conservar la lista original de identificadores de producto asociados a cada transacción sin alterar el grano de la tabla de hechos, facilitando su posterior procesamiento o desglose en fases avanzadas del proyecto.

5. Proceso y orden de carga (Pipeline ETL)

Con el objetivo de evitar conflictos de dependencias por claves foráneas, la ejecución de los scripts sigue un orden estrictamente secuencial:

1. Creación de la base de datos transactions_dw y de las tablas de preparación (stg_*).
2. Carga de los datos brutos desde los archivos CSV a la zona de staging.
3. Definición de la estructura DDL de las tablas finales del modelo dimensional.
4. Carga de las dimensiones independientes (dim_user y dim_company).
5. Carga de la dimensión dependiente (dim_credit_card) y del calendario (dim_date).
6. Carga final de la tabla central de hechos (fact_transactions).